

Proyecto

Resultados.

INTRODUCCIÓN:

Luego de haber realizado un análisis exploratorio detallado tiene una mejor comprensión de los datos y alguna de las preguntas lo llevó a detectar un problema científico que vale la pena abordar. Para esto realizaremos modelos predictivos por lo que el siguiente paso es seleccionar la variable respuesta.

Una vez seleccionada la variable respuesta, deben investigar qué algoritmos se han utilizado para resolver problemas similares. La búsqueda de antecedentes es un paso importante en cualquier investigación científica, por lo que debe buscar en fuentes confiables proyectos desarrollados en un tema similar al suyo. Esto le dará idea de las formas en que han sido abordados problemas similares y los posibles algoritmos que comúnmente se usan.

Ya teniendo idea de cuáles son los algoritmos que serían más útiles en el problema que están resolviendo y seleccionado los que usará para hacer modelos en el proyecto final. Debe aplicarlos y describir los resultados obtenidos. Debe presentar un informe con las explicaciones de cada una de las decisiones tomadas para correr los algoritmos y con los resultados obtenidos. Incluya también el código utilizado.

ACTIVIDADES

1. Determine cuál será su variable respuesta, explique las características (cuantitativa o cualitativa) y el porqué de su elección. **Cada grupo debe resolver un problema distinto por lo que dos grupos no pueden tener la misma variable respuesta.**
2. Haga una investigación para encontrar, en fuentes confiables, proyectos que hayan tratado problemas similares.
3. Redacte una sección de “Antecedentes” (al menos 2 páginas) donde describa los artículos que encontró en la investigación que hizo. Debe referenciar las fuentes utilizadas, y estas deben ser accesibles y verificables por los evaluadores.
4. En base a los antecedentes estudiados, determine qué algoritmos de aprendizaje de máquinas son los más útiles para predecir el valor de la variable respuesta. Debe valorar al menos 3 algoritmos diferentes, puede considerar los que estudiaremos en el curso o cualquier otro que cree que resulte adecuado dada su investigación.
5. Explique el método que siguió para obtener los conjuntos de entrenamiento y prueba, el porcentaje de datos que hay en cada uno y si se encuentran balanceados o no, en caso de que la variable respuesta sea categórica. Si es cuantitativa analice los atípicos.
6. Utilice los algoritmos que determinó que serían los más útiles para aplicar a sus datos. Explique las transformaciones y/o el preprocesamiento que tuvo que hacer para aplicarlos correctamente.
7. Cree varios modelos, (al menos 3 con cada algoritmo) con los algoritmos seleccionados. Varíe los parámetros buscando el mejor modelo sin caer en un modelo desajustado o sobreajustado. Construya un modelo final con los mejores parámetros. Explique con datos como llegó a ellos.
8. Discuta los resultados de los algoritmos incluyendo la matriz de confusión obtenida, en caso de que sea un problema de clasificación, o la métrica de error que considere mejor si el problema es de regresión. Recuerde incluir textos y gráficas (de ser necesarias) para apoyar su explicación.

EVALUACIÓN

- **(10 puntos).** Selección de la variable respuesta y explicación de las transformaciones realizadas a la variable y al conjunto de datos.
- **(25 puntos).** Redacción de los antecedentes para solución de problemas similares. La investigación incluye proyectos similares tanto en el mundo como en áreas más cercanas al país. La bibliografía está bien referenciada usando las normas APA, se puede acceder a las fuentes de las que se extrajo y son fuentes confiables.
- **(10 puntos).** Selección de algoritmos. Se consideraron más de 3 posibles algoritmos de aprendizaje automático para ser utilizados para predecir el valor de la variable respuesta, y la selección de los tres que se usarán se hizo en base a la investigación realizada.
- **(5 puntos)** Explicación del método utilizado para obtener los conjuntos de entrenamiento y prueba.
- **(10 puntos).** Generación de modelos con los algoritmos seleccionados al conjunto de datos de entrenamiento.
- **(40 puntos).** Predicción con los modelos generados. Generación de las matrices de confusión (en caso de ser un problema de clasificación), o las métricas de error en caso de ser un modelo de regresión. Explicación de los resultados obtenidos en cualquiera de los casos. Explicación de los modelos generados, las diferentes variaciones de los parámetros que se probaron. Selección del mejor modelo, de acuerdo con sus parámetros y resultados. Revisión del ajuste del modelo.

Notas:

- Si no se pueden acceder o no existe las referencias bibliográficas, no se le calificará la entrega.
- La descripción y explicación de resultados es crucial en el análisis de los datos por lo que no se tomarán en cuenta gráficos o tablas que no estén explicadas ni para avances ni para entrega final.
- Se tomarán en cuenta las contribuciones individuales para calificar el proyecto, si no tiene suficientes contribuciones significativas en código y en análisis no tiene derecho a nota.

MATERIAL A ENTREGAR

- Documento de Word, con control de cambios o Google docs donde se aprecien las contribuciones de todos los integrantes del grupo.
- Documento .pdf con lo solicitado en las secciones de actividades y evaluación.
- Script de R (.r o .rmd) o de Python que utilizó con el código utilizado.
- Vínculo de repositorio de github

SUGERENCIAS

- Se sugiere usar la herramienta [Mendeley](#) para manejar la bibliografía
- El recurso digital EBSCOhost de la [Biblioteca](#) tiene muy buenos artículos indexados.
- La subscripción a la IEEE Computer Society le puede servir también, está en la [Biblioteca](#).
- La red social para investigación [ResearchGate](#) tiene también muy buenos artículos.